01 / LifeMap | Entrega 1

Informe técnico académico - 7 de noviembre de 2026
Presupuesto: $0 COP. Alcance: ingesta, sentimiento, tasas de cierre y API local. No se implementa Entrega 2.

Población cargada	Reseñas clasificadas	Estado de entrega
16.944 negocios	1.320.594	Funcional local; despliegue externo pendiente

Arquitectura ejecutada

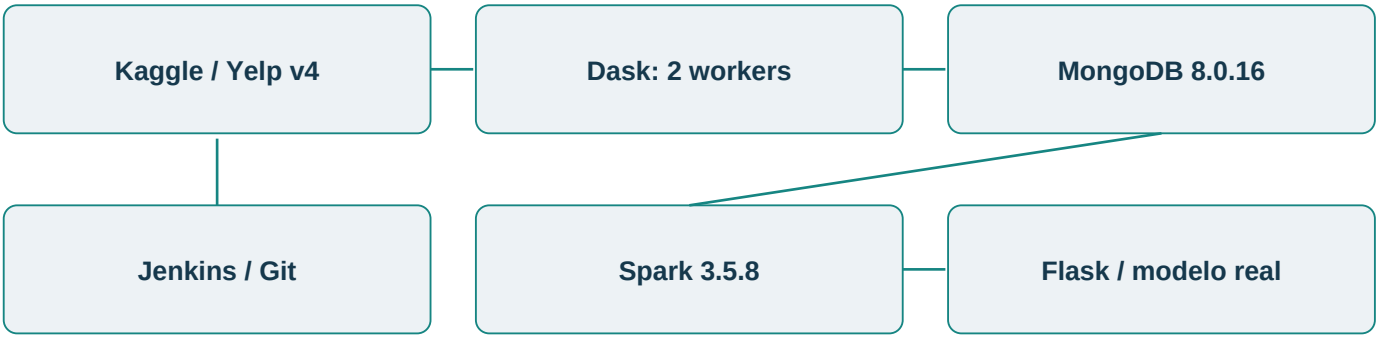

Compose propio **lifemap**: ocho contenedores, redes independientes y nueve volúmenes persistentes. MongoDB autenticado sin puerto host; Dask y Spark procesan dentro de Docker. API usa lector y el export del modelo; Jenkins realiza checkout, pruebas y promoción local. Conector MongoDB Spark 10.7.0.

Reproducibilidad y aislamiento

Imagen base por digest y dependencias fijadas. Python del host: .venv 3.10.11, sin paquetes globales. Descarga v4 con manifiesto SHA256; Parquet, modelos y resultados reutilizables. Fuente, configuración y pipeline en Git local; credenciales, datasets y volúmenes excluidos. Geoespacial y Discos se consultaron sin alterar sus recursos.

El README documenta arranque desde cero, secretos nuevos, builds secuenciales y comandos de procesamiento. Esta instalación local sí se probó; un arranque en otro equipo limpio todavía no se demostró. Puertos administrativos y API ligados a 127.0.0.1; no hay publicación externa.

Selección con autorización del usuario

Restaurants, Filadelfia y entorno: rectángulo [-76.1, 39.3, -74.4, 40.6]. Supera el mínimo de un millón de reseñas únicas. Es un recorte exploratorio, no una delimitación metropolitana oficial. Sigue pendiente comunicarlo al profesor y comprobar exclusividad con otros equipos.

02 / Datos y vida observada

Fuente: **yelp-dataset/yelp-dataset, versión 4**, actualización 17-03-2022. JSONL: negocio con 14 campos y reseña con 9. Claves: business_id y review_id; ubicación decimal, categorías, is_open, texto, estrellas y fecha. Corte máximo de reseñas: 19-01-2022 19:48:45; mínimo: 16-02-2005 03:23:22.

Limpieza cuantificada sobre la fuente completa

Regla negocios	Antes / despues (ret.)	Regla resenas	Antes / despues (ret.)
JSON invalido	150.346 / 150.346 (0)	JSON invalido	6.990.280 / 6.990.280 (0)
Sin coordenadas	150.346 / 150.346 (0)	Sin review_id	6.990.280 / 6.990.280 (0)
Coordenadas no numericas	150.346 / 150.346 (0)	Sin business_id	6.990.280 / 6.990.280 (0)
Coordenadas fuera de rango	150.346 / 150.346 (0)	Texto vacio	6.990.280 / 6.990.280 (0)
Sin business_id	150.346 / 150.346 (0)	Fecha invalida	6.990.280 / 6.990.280 (0)
is_open invalido	150.346 / 150.346 (0)	Estrellas invalidas	6.990.280 / 6.990.280 (0)
Tipo categorias invalido	150.346 / 150.346 (0)	business_id huerfano	6.990.280 / 6.990.280 (0)
Duplicados	150.346 / 150.346 (0)	Negocio descartado	6.990.280 / 6.990.280 (0)
-	-	Duplicados	6.990.280 / 6.990.280 (0)

Filtro autorizado Restaurants + rectangulo: 150.346 negocios limpios a 16.944; 6.990.280 resenas limpias a 1.320.594 (5.669.686 fuera de alcance, no errores).

Cada regla individual conserva los mismos conteos antes/después: no hubo descartes en esta fuente bajo las validaciones aplicadas. Esto no prueba ausencia de otros errores semánticos. El JSON de evidencia conserva todas las reglas, esquemas y huellas; fixtures introducen errores y duplicados para comprobar que sí se detectan.

Coordenadas finitas y válidas evitan geometrías inválidas; IDs permiten joins estables; texto/fecha/estrellas válidos permiten NLP y vida observada. Deduplicación global por ID: primera fila válida en orden físico. Join por business_id: **0 huérfanas**. Dask lee bloques de 8 MiB (14 particiones de negocios, 636 de reseñas), usando ambos workers; caché compartida persistente y deduplicación SQLite en disco del coordinador.

Modelo MongoDB y aproximaciones explícitas

businesses: _id=business_id, Point [longitud, latitud], índice 2dsphere; reviews: _id=review_id y referencia business_id indexada. Upserts ReplaceOne en lotes de 500; una carga completa verificada se reutiliza sin borrar el enriquecimiento. La idempotencia se comprobó con fixtures y reutilización de la carga real.

Días-negocio = (última reseña - primera reseña)/86.400 segundos. Una fecha única aporta cero días. Evento = 1 si is_open=0; censura = 1 si is_open=1. No se prolonga la observación hasta el corte. Fechas civiles de Yelp sin zona conocida; apertura/cierre real y edad antes de la primera reseña son desconocidos. Las reseñas aproximan la vida, con sesgos de selección y actividad: no son historia completa de supervivencia.

03 / Sentimiento real con Spark

Texto → minúsculas/limpieza [a-z] → tokenización → stopwords inglesas → máximo 256 tokens → HashingTF (8.192) → IDF → clasificador. IDF ajustado solo en train. Estrellas: 1-2 negativo, 3 neutral, 4-5 positivo; se eliminan de las características. División determinista por hash de business_id: **13.555 negocios train, 3.389 test; intersección cero**.

Clase	Train	Test	Total (%)
Negativo	226.163	55.862	282.025 (21.4%)
Neutral	133.415	32.691	166.106 (12.6%)
Positivo	700.970	171.493	872.463 (66.1%)

Modelo / clase	Precision	Recall	F1
NB / negativo	0.7258	0.7299	0.7278
NB / neutral	0.3483	0.5618	0.4300
NB / positivo	0.9335	0.8227	0.8746
NB / macro F1	-	-	0.6775
LR / negativo	0.8202	0.7644	0.7913
LR / neutral	0.5547	0.1745	0.2654
LR / positivo	0.8452	0.9744	0.9052
LR / macro F1	-	-	0.6540

Matrices de confusión (filas reales / columnas predichas)

Modelo / real	Negativo	Neutral	Positivo
NB / neg.	40.772	12.586	2.504
NB / neutral	6.772	18.366	7.553
NB / pos.	8.633	21.776	141.084
LR / neg.	42.703	2.308	10.851
LR / neutral	7.241	5.703	19.747
LR / pos.	2.123	2.270	167.100

Mayoría positiva (66,1%): accuracy favorece esa clase. NB: accuracy 0,7699, macro F1 0,6775; LR: 0,8287 y 0,6540. Se selecciona **Naive Bayes** por macro F1; neutral sigue siendo difícil. NB smoothing=1; LR 12 iteraciones, reg=0,1; sin búsqueda extensa. La comparación usa el mismo test, no una evaluación final independiente.

PipelineModel Spark y pesos/IDF guardados. Paridad Spark/API: 30 textos reales, mismas clases y probabilidades con tolerancia 10^-6. Las 1.320.594 reseñas tienen predicción persistida. La procedencia literal de SentimentStream queda pendiente: su fuente no fue suministrada; se implementó el flujo exigido, sin atribuir una reutilización inexistente.

04 / MapReduce y exposición

Adaptación de Discos: emitir **(clave, (evento, días-negocio))** para categoría principal y geohash; sumar con reduceByKey. Una implementación independiente groupBy/sum de DataFrame verifica todas las claves, cierres y exposición (tolerancias 10^-10 relativas / 10^-6 absolutas para días).

Resultado verificado	Valor
Negocios / cierres observados	16.944 / 5.753
Exposición acumulada	43,435,605.035 días-negocio
Agrupaciones	210 categorías derivadas / 390 celdas geohash
RDD frente a DataFrame	Coinciden ambas agregaciones
Tasa global descriptiva	4.834 cierres por 100 negocios-año

Fórmula y umbral

Tasa (%) = cierres / (días-negocio / 365) × 100. No es el porcentaje simple de negocios cerrados. Se exigen 3.650 días agregados (10 negocios-año) para comparar grupos, evitando dividir por exposición casi nula. Es una heurística operativa, no un intervalo de confianza; la tasa puede superar 100 y no se interpreta como probabilidad individual.

Grupos reales de ejemplo, ordenados por cierres

Categoría derivada	Negocios	Cierres	Días	Tasa anual
American (New)	1.902	831	5.016.562	6.046
American (Traditional)	1.788	557	5.088.806	3.995
Italian	988	381	2.737.355	5.080
Pizza	994	266	2.874.622	3.377
Breakfast & Brunch	749	254	1.797.726	5.157

Categoría principal reproducible: primer tag alfabético excluyendo Restaurants, Food y Nightlife, o Restaurants como fallback. Yelp no declara una categoría principal oficial; esta decisión cambia los grupos, no la población de restaurantes. Geohash de precisión 5, con polígono de celda guardado.

Persistencia y reputación geográfica

Colección closure_stats: clave, cierres, días, negocios, tasa, run_id y, por celda, geometría y porcentaje de reseñas negativas. businesses conserva resumen de sentimiento y geohash; reviews conserva clase, probabilidades y modelo. Una zona combina estas estadísticas con $geoNear y exposición real. El porcentaje negativo usa predicciones del modelo seleccionado, no se confunde con los días-negocio.

Limitaciones: is_open es un estado del dataset y no una fecha de cierre; primera/última reseña dependen de actividad. Agrupaciones con exposición pequeña o categoría derivada requieren cautela. No se hicieron inferencias causales, Kaplan-Meier ni predicción de cierre (E2).

05 / Particiones y recursos

24 mediciones reales: 2, 8, 32 y 200 particiones; reparto por ciudad frente a round-robin sin clave; tres repeticiones por caso. Una pareja de reducciones sin medir calienta cada configuración. Se materializan los 16.944 negocios antes del cronómetro; se incluyen repartición, dos reduceByKey, collect y comprobación DataFrame. Spark 3.5.8, un worker y un núcleo.

N / reparto	T1 / T2 / T3 (s)	Media	Mediana	DE muestral
2 / ciudad	1.01 / 0.75 / 0.75	0.83	0.75	0.150
2 / sin clave	0.95 / 0.79 / 0.69	0.81	0.79	0.129
8 / ciudad	2.21 / 2.04 / 2.19	2.15	2.19	0.096
8 / sin clave	2.14 / 2.33 / 2.04	2.17	2.14	0.148
32 / ciudad	8.56 / 8.48 / 8.17	8.40	8.48	0.205
32 / sin clave	8.02 / 7.92 / 7.84	7.93	7.92	0.094
200 / ciudad	44.93 / 44.16 / 43.67	44.25	44.16	0.637
200 / sin clave	46.94 / 46.43 / 46.42	46.60	46.43	0.295

Sesgo observado con spark_partition_id()

N	Ciudad: mín./máx. filas	Vacías	Sin clave: mín./máx.
2	4503 / 12441	0	8472 / 8472
8	1028 / 7634	0	2118 / 2118
32	127 / 6596	0	529 / 530
200	0 / 5854	19	84 / 85

Con 200 particiones, ciudad concentra hasta 5.854 filas y deja 19 vacías; sin clave distribuye 84-85 filas. Un reparto equilibrado no garantiza menos tiempo: en este equipo pequeño el costo de tareas domina. Dos particiones son más rápidas; no se extrapola escalabilidad a millones de negocios ni a varios nodos físicos.

Memoria medida y recuperación

La primera publicación se detuvo de forma segura a 0,468 GiB libres en Windows (96% de carga), sin OOM ni borrar datos. El usuario liberó memoria manualmente y se reanudó desde Parquet/modelo, sin reentrenar. Publicación final: mínimo 1,651 GiB libres, pico CPU Windows 33,7%; analytics: mínimo 1,714 GiB, pico 24,9%. Son muestras del host, no CPU exclusiva del job.

Límites por contenedor suman 6.625 GiB; Windows/WSL comparten memoria y no se contabilizan dos veces. Procesos intensivos se ejecutan secuencialmente; no se cambiaron ajustes globales. Consumo al cierre y muestras por contenedor se conservan en e1-evidence.json. La caché original tuvo que descargarse de nuevo una vez tras detectar un montaje faltante; fue corregido y la reutilización posterior sí está verificada.

06 / API, CI y aceptación

Endpoint	Comprobación real
GET /health	API, Mongo, Spark, Dask y commit real
GET /businesses/near	$near, categoría/radio/límite variables
POST /businesses/within	$geoWithin, polígono validado
GET /zones/summary	$geoNear, sentimiento y tasa por zona
GET /stats/closure	Categoría/geohash y exposición mínima
POST /predict	Modelo NB real; probabilidades de texto

Seis endpoints probados contra la población real; entradas inválidas devuelven 400. Límite 100 filas, radio 50 km y consultas Mongo con timeout; errores de dependencia 503 sin secretos. API usa solo lector; modelo exportado validado SHA256 y equivalente al de Spark.

Evidencia de pruebas y Jenkins

Pruebas: 21 unittest locales, 13 pytest Docker, fixtures distribuidos en ambos workers con GeoJSON/idempotencia, paridad de 30 textos, igualdad RDD/DataFrame y 24 benchmarks. Historial local Jenkins: #1 FAILURE, #2 SUCCESS, #3 FAILURE, #4 SUCCESS, #5 FAILURE. Detalle de parámetros, JUnit y artifacts en e1-jenkins.json.

Jenkins usa checkout de Git bundle local, builds secuenciales, pytest, infraestructura, caché/ingesta, resultados académicos, API candidata y promoción local. Build #4 exitoso; #5 falla intencionalmente en pytest, omite despliegue y conserva exactamente la imagen anterior de la API. Credencial Kaggle registrada en Jenkins. GitHub origin conserva visibilidad pública, sin push; pollSCM cada dos minutos preparado y job remoto deshabilitado hasta autorización.

Aceptación: no confundir local con público

E1.1: Compose/README y salud local; falta equipo limpio externo. **E1.2:** pendiente servidor distinto y URL pública. **E1.3:** pipeline/gate locales; falta merge remoto y disparo por main. **E1.4-E1.5:** ingesta/datos/vida comprobados. **E1.6:** modelos y métricas reales; falta verificar reutilización literal de SentimentStream. **E1.7-E1.8:** agregación y benchmark completos. **E1.9:** seis rutas locales, falta URL desplegada. **E1.10:** informe/README; sustentación y cambio remoto en vivo pendientes.

Pendientes externos: segundo equipo gratuito autorizado, disponibilidad pública, primer push autorizado y profesor (exclusividad de selección). Procedimiento sin costo en DEPLOYMENT.md; ningún servicio contratado ni administrativo expuesto. No se inventan autores/aportes. Power BI queda para E2; Kafka, streaming, supervivencia y riesgo no implementados.

Fuentes: Word oficial LifeMap (Insumos), §§4, 6 y 7, rúbrica E1.1-E1.10; fecha de entrega actualizada por el usuario. Yelp/Kaggle: https://www.kaggle.com/datasets/yelp-dataset/yelp-dataset (v4). Adaptaciones: docs/REUSE.md; Spark HashingTF/MurmurHash3, código Apache Spark 3.5.8. Evidencia reproducible: docs/reports/e1-evidence.json y e1-jenkins.json.